

탐색적 데이터 분석(EDA) 실습

ggplot2 패키지를 활용한 단일변수 · 다변수 시각화 실습

0. 사전 준비: 패키지 설치 및 데이터 불러오기

아래 패키지는 최초 1회만 설치하면 되며, 이후에는 library()로 불러오기만 하면 됨.

```
install.packages("tidyverse")
install.packages("readxl")
install.packages("writexl")
```

라이브러리 로딩

```
library(tidyverse)
library(readr)
library(readxl)
library(writexl)
library(lubridate)
```

작업폴더 설정(본인의 폴더로 지정) 및 데이터 불러오기

```
setwd("각자 작업폴더 설정")
df <- read_excel("insurance2.xlsx")
View(df) # 대문자 V 주의
```

1. 단일변수 시각화 (연속형 / 범주형)

1-1. 연속형 데이터 분포 확인 (Histogram · Density · Box Plot)

base R로 빠르게 분포를 확인함

```
hist(df$bmi)
hist(df$나이)
```

ggplot2로 histogram 그리기 — aes()는 축 설정 옵션, geom_은 그래프 종류를 지정함

예제 1) Histogram

```
df %>%
  ggplot(aes(x = bmi)) +
  geom_histogram()
```

→ 막대 테두리 색을 지정하려면 col 옵션 추가

```
df %>%
  ggplot(aes(x = bmi)) +
  geom_histogram(col = 'white')
```

예제 2) Density (밀도함수)

```
df %>%
  ggplot(aes(x = bmi)) +
  geom_density(col = "orange", size = 1) +
  theme_minimal()
```

예제 3) Box Plot

```
df %>%
  ggplot(aes(x = bmi)) +
  geom_boxplot(fill = 'skyblue', col = 'orange', size = 1) +
  theme_minimal()
```

1-2. 범주형 데이터 빈도수 확인 (Bar Chart)

예제 1) 지역별 빈도

```
df %>%
  ggplot(aes(x = 지역)) +
  geom_bar(fill = "skyblue") +
  theme_minimal()
```

예제 2) filter()로 조건에 맞는 데이터만 추출 후 시각화

지역이 southeast인 경우의 성별 분포

```
df %>%
  filter(지역 == "southeast") %>%
  ggplot(aes(x = 성별)) +
  geom_bar(fill = "skyblue") +
  theme_minimal()
```

지역이 southeast 또는 northwest인 경우의 성별 분포 (두 가지 작성 방법)

```
df %>%
  filter(지역 == "southeast" | 지역 == "northwest") %>%
  ggplot(aes(x = 성별)) +
  geom_bar(fill = "skyblue") +
  theme_minimal()

df %>%
  filter(지역 %in% c("southeast", "northwest")) %>%
  ggplot(aes(x = 성별)) +
  geom_bar(fill = "skyblue") +
  theme_minimal()
```

지역이 southeast 또는 northwest이고, 성별이 남성인 경우의 흡연여부 분포

```
df %>%
  filter(지역 %in% c("southeast", "northwest") & 성별 == "male") %>%
  ggplot(aes(x = 흡연여부)) +
  geom_bar(fill = "skyblue") +
  theme_minimal()
```

예제 3) labs()로 제목·축 이름 지정하기

자녀수에 대한 막대그래프(bar chart) 시각화

```
df %>%
  ggplot(aes(x = as.factor(자녀수))) +
  geom_bar(fill = "lightpink") +
  labs(title = "자녀수 빈도", x = "자녀수", y = "빈도") +
  theme_minimal()
```

2. 다변수 시각화

2-1. X: 범주형 · Y: 연속형 — 집단 간 통계량 비교 (group_by · summarise · geom_col)

예제 1) 성별에 따른 bmi 평균

```
df %>%
  group_by(성별) %>%
  summarise(bmi평균 = mean(bmi)) %>%
  ggplot(aes(x = 성별, y = bmi평균)) +
  geom_col(fill = 'skyblue') +
  theme_minimal()
```

예제 2) 자녀수(부양가족)에 따른 의료비 청구 평균

```
df %>%
  group_by(자녀수) %>%
  summarise(의료비평균 = mean(의료비)) %>%
  ggplot(aes(x = 자녀수, y = 의료비평균)) +
  geom_col(fill = "skyblue") +
  theme_minimal()
```

예제 3) 지역별 평균 bmi를 성별로 구분 (fill 옵션으로 그래프 overlay)

```
df %>%
  group_by(지역, 성별) %>%
  summarise(평균bmi = mean(bmi)) %>%
  ggplot(aes(x = 지역, y = 평균bmi, fill = 성별)) +
  geom_col(position = 'dodge') +
  theme_minimal()
```

예제 4) 흡연여부에 따른 평균 의료비

```
df %>%
  group_by(흡연여부) %>%
  summarise(의료비평균 = mean(의료비)) %>%
  ggplot(aes(x = 흡연여부, y = 의료비평균)) +
  geom_col(fill = "skyblue") +
  theme_minimal()
```

실습 문제 1

흡연여부 및 성별에 따른 평균 의료비를 시각화하되, 성별에 따라 구분할 것

```
df %>%
  group_by(흡연여부, 성별) %>%
  summarise(의료비평균 = mean(의료비)) %>%
  ggplot(aes(x = 흡연여부, y = 의료비평균, fill = 성별)) +
  geom_col(position = 'dodge') +
  theme_minimal()
```

실습 문제 2

성별 및 흡연여부에 따른 평균 bmi를 시각화하되, 흡연여부에 따라 구분할 것

```
df %>%
  group_by(성별, 흡연여부) %>%
  summarise(평균bmi = mean(bmi)) %>%
  ggplot(aes(x = 성별, y = 평균bmi, fill = 흡연여부)) +
  geom_col(position = 'dodge') +
  theme_minimal()
```

2-2. X: 연속형 · Y: 연속형 — 산점도 (geom_point)

예제 1) 나이와 bmi

```
df %>%
  ggplot(aes(x = 나이, y = bmi)) +
  geom_point()
```

예제 2) bmi와 의료비

```
df %>%
  ggplot(aes(x = bmi, y = 의료비)) +
  geom_point() +
  theme_minimal()
```

예제 3) 나이와 의료비 + 회귀선(geom_smooth)

```
df %>%
  ggplot(aes(x = 나이, y = 의료비)) +
  geom_point() +
  geom_smooth() +
  theme_minimal()
```

2-3. X: 순서형 · Y: 연속형 — 시간 추이 (Line Chart)

월/요일 변수 추출을 위한 데이터 전처리 (lubridate 활용)

```
df$청구월 <- month(df$청구일)
df$청구요일 <- wday(df$청구일, label = TRUE)
```

예제 1) 월별 의료비 청구 합계

```
df %>%
  group_by(청구월) %>%
  summarise(의료비청구 = sum(의료비)) %>%
  ggplot(aes(청구월, y = 의료비청구)) +
  geom_line() +
  theme_minimal()
```

예제 2) 1~12월 순서 표시를 위해 청구월을 factor로 변환

```
df %>%
  group_by(청구월) %>%
  summarise(의료비청구 = sum(의료비)) %>%
  ggplot(aes(x = as.factor(청구월), y = 의료비청구)) +
  geom_line(group = 1, col = "lightpink", linewidth = 2) +
  theme_minimal()
```

실습 문제 1

요일별 의료비청구 평균을 line 그래프로 시각화할 것

Tip

x축 변수가 범주형(factor 또는 character)일 때 선을 연결하려면 group = 1을 사용해 모든 데이터를 한 그룹으로 묶어주어야 함

```
df %>%
  group_by(청구요일) %>%
  summarise(의료비 = mean(의료비)) %>%
  ggplot(aes(x = 청구요일, y = 의료비)) +
  geom_line(group = 1, col = "skyblue", linewidth = 1) +
  theme_minimal()
```

실습 문제 2

요일별 의료비청구 평균을 막대 그래프(geom_col)로 시각화할 것

```
df %>%
  group_by(청구요일) %>%
  summarise(의료비 = mean(의료비)) %>%
  ggplot(aes(x = 청구요일, y = 의료비)) +
  geom_col(fill = 'skyblue') +
  theme_minimal()
```