



HEALTH ADMINISTRATION · SURVEY METHODOLOGY

R을 이용한 조사방법론

Ch4. R 프로그래밍 기초 : 탐색적 데이터 분석(EDA)

경민대학교 보건의료행정과 · 최정웅 교수

통계적 데이터 분석 절차 개관

실무에서 인사이트를 얻기 위한 데이터 분석은 아래 4단계를 순서대로 거침



통계적 데이터 분석 절차



STEP 2. 탐색적 데이터 분석 (EDA)

1 변수 간 관계 파악

목표변수와 설명변수 간의 관계·연관성·상관성 등을 파악

2 데이터 경향성 확인

데이터의 trend(추세)를 확인

3 데이터 시각화

그래프 등을 통해 데이터를 시각적으로 탐색

데이터 시각화 ① 단일 변수 탐색

연속형 (숫자 데이터 분포)

Histogram

숫자 데이터 분포를 막대로 표현 **x:구간** **y:빈도**

KDE

확률분포를 계산해 선으로 표현 **x:구간** **y:확률**

Box Plot

사분범위(IQR)로 분포 표현 **x:구간** **y:분위**

한 가지 항목(변수)을 대상으로 분포·경향을 확인하는 것이 단일 변수 시각화임

범주형 (항목과 빈도수)

Bar Chart

항목별 빈도수를 막대 길이로 비교 **성별·지역**

Pie Chart

전체 대비 항목의 비율을 표현 **구성비 (%)**

💡 핵심 포인트

연속형 데이터는 '분포의 모양'을, 범주형 데이터는 '항목 간 비교'를 보기 위해 시각화함

데이터 시각화 ② 다변수 관계 탐색

두 변수 이상의 관계를 시각화할 때는 각 변수의 데이터 타입 조합에 따라 적합한 그래프가 달라짐

Bar Chart

집단 간 통계량(평균 등) 비교

x: 범주형 · y: 연속형

Scatter Plot

두 변수의 산점도 · 상관성 확인

x: 연속형 · y: 연속형

Line Chart

시간 흐름에 따른 추이 확인

x: 순서형 · y: 연속형

단일 변수 시각화: 히스토그램 & 박스플롯

실습 준비

insurance.csv 데이터의 '의료비(charges)' 변수 분포를 시각화함

히스토그램 (Histogram)

```
hist(df$의료비,  
      main = "의료비 분포",  
      xlab = "의료비", ylab = "빈도",  
      col  = "skyblue")
```

→ X축: 의료비 구간, Y축: 해당 구간의 빈도(도수)

박스 플롯 (Box Plot)

```
boxplot(df$의료비,  
         main = "의료비 분포",  
         ylab = "의료비",  
         col  = "orange")
```

→ 중앙값 · 사분범위(IQR) · 이상치를 한눈에 확인

💡 핵심 요약: 히스토그램은 분포의 '모양'을, 박스플롯은 분포의 '요약 통계량과 이상치'를 보여줌

범주형 데이터 시각화: 막대 & 원 그래프

실습 준비

성별 · 지역 등 범주형 변수의 빈도수를 table()로 먼저 집계한 뒤 시각화함

막대 그래프 (Bar Chart)

```
barplot(table(df$성별),  
        main = "성별 분포",  
        col = c("skyblue", "pink"))
```

→ 막대의 길이로 항목별 빈도수(개수)를 비교

원 그래프 (Pie Chart)

```
pie(table(df$지역),  
    main = "지역별 분포")  
  
# 조각(%) 강조 시 pie() + labels 활용
```

→ 부채꼴 크기로 전체 대비 각 항목의 구성비를 표현

💡 핵심 요약: 항목 수가 많거나 비율 비교가 중요하지 않다면 파이 차트보다 막대 그래프가 더 정확하게 읽힘

다변수 시각화: 산점도 & 상관관계

실습 준비

연령(x)과 의료비(y) 두 연속형 변수 간의 관계를 산점도와 상관계수로 확인함

산점도 (Scatter Plot)

```
plot(df$연령, df$의료비,  
      main = "연령과 의료비",  
      xlab = "연령", ylab = "의료비",  
      pch = 19, col = "steelblue")
```

→ 점들이 흩어진 방향과 폭으로 관계의 방향·강도를 관찰

상관계수 (Correlation)

```
cor(df$연령, df$의료비)  
  
# [1] 0.68 → 뚜렷한 양의 상관
```


→ -1 ~ +1 사이 값으로 관계의 방향·강도를 수치화

💡 핵심 요약: 산점도로 관계의 '패턴'을 눈으로 보고, 상관계수로 그 강도를 '숫자'로 확인함

2. 탐색적 데이터 분석(EDA) 실습

상관계수(r)의 이해

데이터가 평균으로부터 흩어진 정도를 보는 것이 산포라면, 상관계수는 두 변수가 함께 움직이는 정도를 봄



해석 기준 (절댓값 |r| 기준)

0.7 ~ 1.0	강한 상관관계
0.3 ~ 0.7	뚜렷한(중간) 상관관계
0.1 ~ 0.3	약한 상관관계
0.0 ~ 0.1	상관관계 거의 없음

유의할 점

상관관계는 두 변수가 '함께 변하는 정도'를 보여줄 뿐, 인과관계(원인과 결과)를 의미하지 않음. 예) 아이스크림 판매량과 익사 사고는 상관이 높지만, 원인은 '기온'이라는 제3의 변수임.

2. 탐색적 데이터 분석(EDA) 실습

패키지 활용: ggplot2

base R 함수 외에, 정교한 시각화를 위해 tidyverse의 ggplot2 패키지를 활용할 수 있음

패키지 설치

Tidyverse는 ggplot2 · dplyr 등 데이터 분석에 필요한 패키지 모음임

ggplot2 산점도 예시

ggplot2의 구조 (문법의 layer)

`ggplot(data, aes(...))`

데이터 & 축(x,y) 매핑 지정

`geom_point()` / `geom_bar()`

그래프의 종류(기하 객체) 지정

`labs()` / `theme()`

제목·축 이름·디자인 설정

```
ggplot(df, aes(x = 연령,  
               y = 의료비)) +  
  geom_point(color = "steelblue") +  
  labs(title = "연령과 의료비",  
        x = "연령", y = "의료비")
```

NEXT STEP

별도 자료로 실습을 진행함

hwp

Ch4_탐색적데이터분석(EDA) 실습

해당 파일을 열어 실습을 이어서 진행할 것.